

Evopy Model Comparison Report

Raport porównawczy modeli LLM dla Evopy

Data wygenerowania: 2025-05-09 15:21:34

Podsumowanie wyników

Wyniki ogólne

Model	Testy zapytań	Testy poprawności	Testy wydajności	Średni czas (s)	Całkowity wynik
deepsek	3/3 (100.0%)	0/0 (0.0%)	0/0 (0.0%)	0.00	3/3 (100.0%)
gpt-4	3/3 (100.0%)	0/0 (0.0%)	0/0 (0.0%)	0.00	3/3 (100.0%)

Dokładność konwersji tekst-na-kod

Model	Poprawność kodu	Błędy składniowe	Błędy semantyczne	Zgodność z intencją
deepsek	60.0%	0.0%	0.0%	54.0%
gpt-4	60.0%	0.0%	0.0%	54.0%

Wydajność kodu

Model | Złożoność czasowa | Ocena | Złożoność pamięciowa | Ocena | Efektywność rozmiaru | Wykorzystanie zasobów | Ogólna ocena |

| --- | --- | --- | --- | --- | --- | --- | | deepsek | O(n) | 0.0% | O(1) | 0.0% | 0.0% | 0.0% | 0.0% | | gpt-4

| O(n) | 0.0% | O(1) | 0.0% | 0.0% | 0.0% | 0.0% |

Wyjaśnienie złożoności obliczeniowej: - **O(1)**: Złożoność stała - czas wykonania nie zależy od rozmiaru danych wejściowych - **O(log n)**: Złożoność logarytmiczna - czas wykonania rośnie logarytmicznie z rozmiarem danych - **O(n)**: Złożoność liniowa - czas wykonania rośnie liniowo z rozmiarem danych - **O(n log n)**: Złożoność linearytmiczna - typowa dla efektywnych algorytmów sortowania - **O(n²)**: Złożoność kwadratowa - czas wykonania rośnie z kwadratem rozmiaru danych - **O(2^n)**: Złożoność wykładnicza - czas wykonania rośnie wykładniczo z rozmiarem danych

Jakość wyjaśnień i kodu

Model | Jakość dokumentacji | Klarowność wyjaśnień | Czytelność kodu | Indeks utrzymywalności |

| --- | --- | --- | --- | --- | | deepsek | 0.0% | 0.0% | 0.0% | 0.0% | | gpt-4 | 0.0% | 0.0% | 0.0% | 0.0% |

Zgodność z intencjami użytkownika

Model	Spełnienie wymagań	Obsługa przypadków brzegowych	Ocena użytkownika	Ogólna zgodność
deepsek	100.0%	80.0%	90.0%	92.0%
gpt-4	100.0%	80.0%	90.0%	92.0%

Wizualizacja wyników

Wykresy porównawcze

```
<canvas id="radar-chart" class="evopy-chart" data-chart='{
  "type": "radar",
  "data": {
    "labels": [
      "Poprawność kodu",
      "Jakość wyjaśnień",
      "Wydajność kodu",
      "Zgodność z intencjami",
      "Testy podstawowe"
    ],
    "datasets": [
```

```
    {
      "label": "deepsek",
      "data": [
        60.0,
        0,
        0,
        92.0,
        100.0
      ],
      "fill": true,
      "backgroundColor": "rgba(54, 162, 235, 0.2)",
      "borderColor": "rgba(54, 162, 235, 1)",
      "pointBackgroundColor": "rgba(54, 162, 235, 1)",
      "pointBorderColor": "#fff",
      "pointHoverBackgroundColor": "#fff",
      "pointHoverBorderColor": "rgba(54, 162, 235, 1)"
    },
    {
      "label": "gpt-4",
      "data": [
        60.0,
        0,
        0,
        92.0,
        100.0
      ],
      "fill": true,
      "backgroundColor": "rgba(255, 99, 132, 0.2)",
      "borderColor": "rgba(255, 99, 132, 1)",
      "pointBackgroundColor": "rgba(255, 99, 132, 1)",
      "pointBorderColor": "#fff",
      "pointHoverBackgroundColor": "#fff",
      "pointHoverBorderColor": "rgba(255, 99, 132, 1)"
    }
  ],
  "options": {
    "elements": {
      "line": {
        "borderWidth": 3
      }
    }
  },
  "scales": {
    "r": {
```

```

        "angleLines": {
            "display": true
        },
        "suggestedMin": 0,
        "suggestedMax": 100
    }
},
"plugins": {
    "title": {
        "display": true,
        "text": "Porównanie modeli w różnych kategoriach"
    }
}
}
}'></canvas>

```

```

<canvas id="test-results-chart" class="evopy-chart" data-chart='{
    "type": "bar",
    "data": {
        "labels": ['deepsek', 'gpt-4'],
        "datasets": [
            {
                "label": "Testy zapytań (%)",
                "data": [100.0, 100.0],
                "backgroundColor": "rgba(54, 162, 235, 0.5)",
                "borderColor": "rgba(54, 162, 235, 1)",
                "borderWidth": 1
            },
            {
                "label": "Testy poprawności (%)",
                "data": [0, 0],
                "backgroundColor": "rgba(75, 192, 192, 0.5)",
                "borderColor": "rgba(75, 192, 192, 1)",
                "borderWidth": 1
            }
        ]
    },
    "options": {
        "scales": {
            "y": {
                "beginAtZero": true,
                "max": 100,

```

```

        "title": {
            "display": true,
            "text": "Procent sukcesu (%)"
        }
    },
    "plugins": {
        "title": {
            "display": true,
            "text": "Porównanie wyników testów"
        }
    }
}
}'</canvas>

```

```

<canvas id="performance-chart" class="evopy-chart" data-chart='{
    "type": "line",
    "data": {
        "labels": ['deepsek', 'gpt-4'],
        "datasets": [
            {
                "label": "Średni czas wykonania (s)",
                "data": [0, 0],
                "backgroundColor": "rgba(255, 99, 132, 0.2)",
                "borderColor": "rgba(255, 99, 132, 1)",
                "borderWidth": 2,
                "tension": 0.1
            }
        ]
    },
    "options": {
        "scales": {
            "y": {
                "beginAtZero": true,
                "title": {
                    "display": true,
                    "text": "Czas (sekundy)"
                }
            }
        }
    },
    "plugins": {
        "title": {

```

```
        "display": true,  
        "text": "Porównanie czasu wykonania"  
    }  
}  
}  
}'></canvas>
```

Analiza trendów

Postępy w czasie

Model: deepsek

- Brak wystarczających danych historycznych do analizy trendów

Model: gpt-4

- Brak wystarczających danych historycznych do analizy trendów

Szczegółowe wyniki testów

Model: deepsek

Wyniki testów zapytań

- Zaliczone testy: 3/3 (100.0%)
- Ilość wygenerowanego kodu: 0 linii
- Średnia ilość linii na zapytanie: 0.0

Wyniki testów poprawności

- Zaliczone testy: 0/0 (0.0%)
- Skuteczność kompilacji: 0.0%
- Skuteczność wykonania: 0.0%

Wyniki testów wydajności

- Brak wyników testów wydajności

Model: gpt-4

Wyniki testów zapytań

- Zaliczone testy: 3/3 (100.0%)
- Ilość wygenerowanego kodu: 0 linii
- Średnia ilość linii na zapytanie: 0.0

Wyniki testów poprawności

- Zaliczone testy: 0/0 (0.0%)
- Skuteczność kompilacji: 0.0%
- Skuteczność wykonania: 0.0%

Wyniki testów wydajności

- Brak wyników testów wydajności

Wnioski

Na podstawie przeprowadzonych testów można wyciągnąć następujące wnioski:

1. **Najlepszy model pod względem poprawności:** (0.0%)
2. **Najszybszy model:** (średni czas: infs)
3. **Najlepszy model ogólnie:** deepsek (ogólny wynik: 100.0%)

Metodologia testów

Testy zostały przeprowadzone w trzech kategoriach:

1. **Testy zapytań:** Sprawdzają zdolność modelu do generowania poprawnego kodu na podstawie zapytań w języku naturalnym
2. **Testy poprawności:** Weryfikują poprawność wygenerowanego kodu i opisów

3. **Testy wydajności:** Mierzą czas wykonania różnych operacji przez model

Zalecenia

Na podstawie wyników testów zalecamy:

1. **Do zadań wymagających wysokiej dokładności:**
2. **Do zadań wymagających szybkiego działania:**
3. **Do ogólnego użytku:** deepsek

Wygenerowano przez Evopy Report Generator

© 2025 Evopy